



Expositor

Joel Alberto Vilca Tarazona



+51 945440723



joelvilcatarazona@gmail.com



www.linkedin.com/in/vilcajoal/

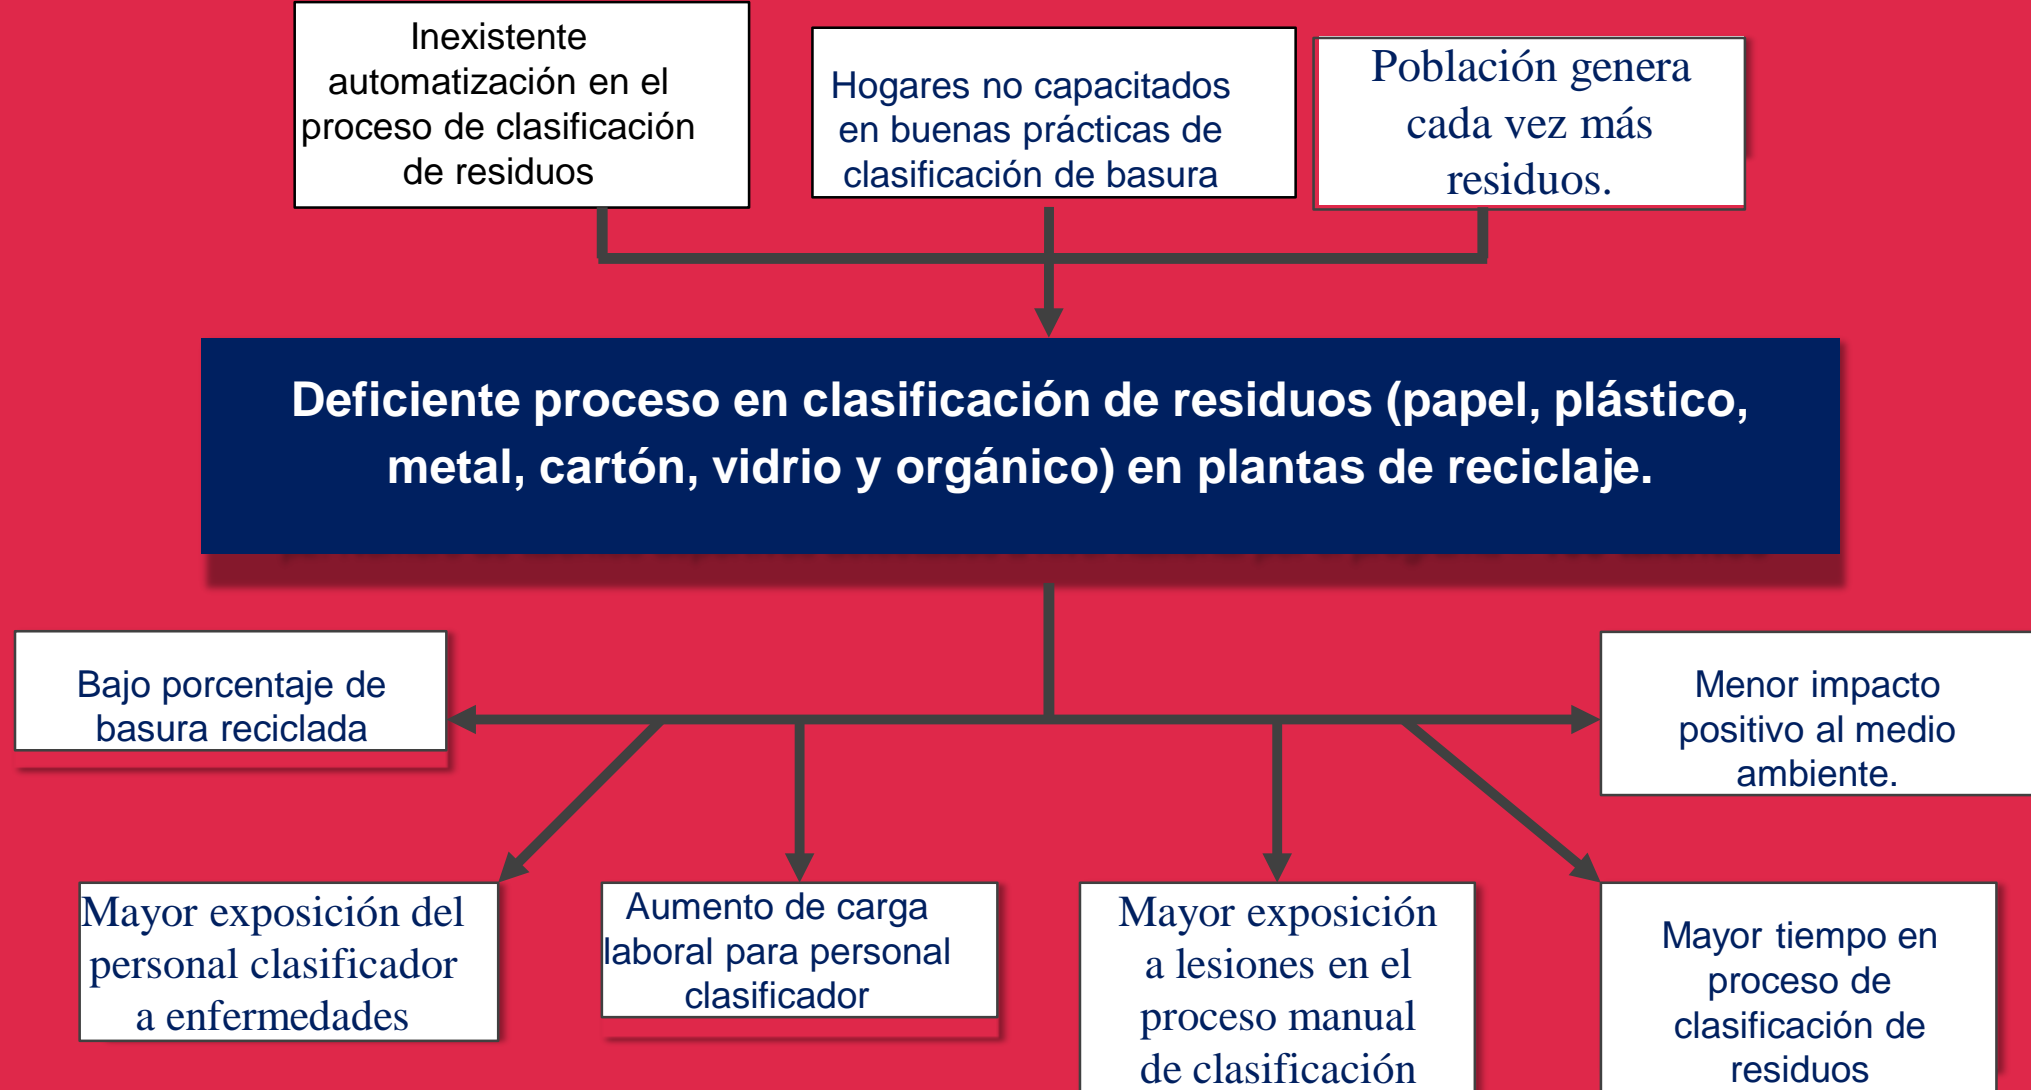
Tema

Sistema inteligente basado en Deep Learning para el proceso de clasificación de residuos

RESUMEN



PROBLEMA



OBJETIVO

Entrenar un algoritmo de clasificación basado en Deep Learning

Realizar sugerencias para proyectos futuros utilizando el modelo

Evaluar y comparar los algoritmos de Deep Learning

Implementar un algoritmo utilizando redes neuronales convolucionales para clasificación de residuos reciclables (papel, plástico, metal, cartón, vidrio y orgánico).

Aumentar el porcentaje de basura reciclada

Aumentar impacto positivo al medio ambiente.

Minimizar exposición del personal clasificador a enfermedades

Disminuir carga laboral para personal clasificador

Minimizar exposición de lesiones en el proceso manual de clasificación

Minimizar tiempo en proceso de clasificación de residuos



MARCO TEÓRICO

Inteligencia Artificial

Algoritmos de
clasificación

Redes Neuronales
Convolucionales

Proceso de reciclaje



Supervisado

Binario

Convolución

Recolectar, acopiar

No supervisado

Multiclase

Detección de rasgos

clasificar, producir

ESTADO DEL ARTE

DEEP LEARNING PARA LA CLASIFICACIÓN Y SEGMENTACIÓN DE IMÁGENES DE ALIMENTOS

Iago Vidal Luna 2018

PROTOTIPO DE SISTEMA AUTOMATIZADO CON VISIÓN ARTIFICIAL PARA LA SELECCIÓN DE EMPAQUES DE PLÁSTICO, VIDRIO Y LATA EN EL PROCESO DE RECICLAJE

DIANA LUZ PACHÓN ESPINEL 2018

Classification for plastic bottles recycling based on image recognition

Zhaokun Wanga, Binbin
Peng

An Innovative Automated Robotic System based on Deep Learning approach for Recycling Objects

Jaeseok Kim, Olivia Nocentini
, Marco Scafuro

Importancia del Deep Learning y específicamente las RNC a la hora de trabajar con imágenes el cual utilicé para implementación del algoritmo utilizando Python y Keras

Tesis

Amplio mi visión sobre las aplicaciones de deep learning en los procesos cotidianos y en la optimización de tareas repetitivas que me sirvió como guía para el algoritmo de clasificación que implementé.

Tesis

Trabajo de clasificación de botellas de plástico en una cinta transportadora en la cual se estudia la influencia del tamaño de la muestra de entrenamiento en el modelo de clasificación y los resultados obtenidos, me ayudó a entender que necesitaba buscar más imágenes para entrenamiento

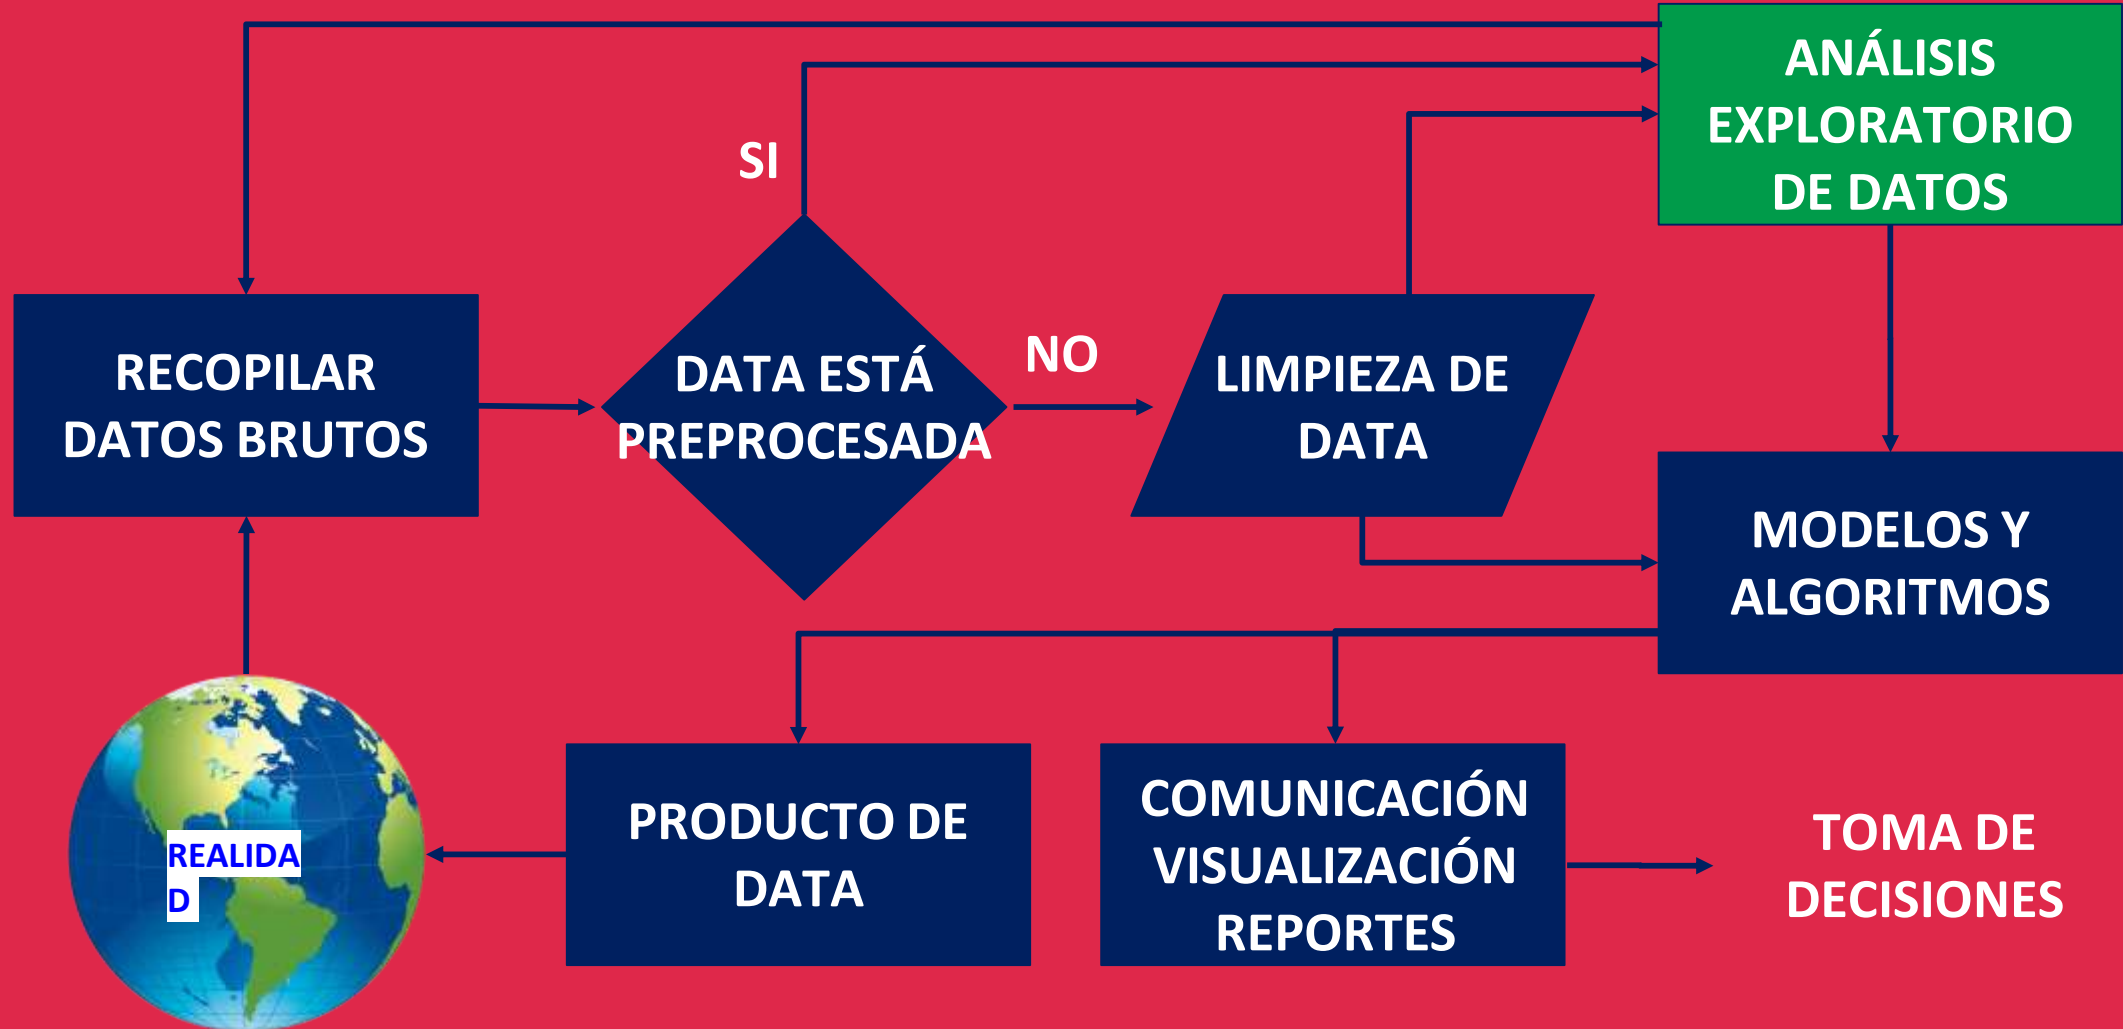
Artículo

Implementación de algoritmo de Deep Learning LeNet junto a un robot para clasificar residuos en plástico y cartón alcanzando precisión del 86.67%, me ayudó a investigar sobre RNC pre entrenadas como VGG16, ResNet50, InceptionResNetV2, Exception.

Artículo

METODOLOGÍA

DATA SCIENCE PROCESS





kaggle



Set de datos de 6,000
imágenes con 6
categorías

- ★ 1,000 vidrio
- ★ 1,000 papel
- ★ 1,000 cartón
- ★ 1,000 plástico
- ★ 1,000 metal
- ★ 1,000 orgánico

trashnet

Código (solo para la red neuronal convolucional) y conjunto de datos para el proyecto final mío y de Mindy'Ying para la clase CS 229: Machine Learning de Stanford. Nuestro artículo se puede encontrar [aquí](#). Los resultados de la red neuronal convolucional en el póster están fechados ya que continuamos trabajando después del final del trimestre y pudimos lograr alrededor del 75% de precisión de la prueba (con 70/13/17 train / val / test split) después de cambiar la inicialización del peso a el método Kaiming.

Conjunto de datos

Este repositorio contiene el conjunto de datos que recopilamos. El conjunto de datos abarca seis clases: vidrio, papel, cartón, plástico, metal y basura. Actualmente, el conjunto de datos consta de 2527 imágenes:

- 501 vidrio
- 594 papel
- 403 cartón
- 482 plástico
- 410 de metal
- 137 basura

```

for i in range(12):
    plt.subplot(2,6,i+1)
    plt.imshow(imgs[i])
    plt.title(rutas[i].split("\\")[1])
    plt.axis("off")

plt.subplots_adjust(left=0.125,
                    bottom=0.1,
                    right=0.9,
                    top=0.4,
                    wspace=0.2,
                    hspace=0.35)

plt.show()

```



```

# imagenes reescaladas a 224x224
img_width = 224
img_height = 224
batch_size = 100

```

aumento y normalizacion de datos

```

datagen_train = ImageDataGenerator(rescale=1.0/255.0,      # Normalizar imagenes en range [0-1]
                                   horizontal_flip=True,   # Volteo horizontal
                                   rotation_range=15,       # Rotación aleatoria entre 0 y 15 grados
                                   width_shift_range=0.15,   # Mover la imagen horizontalmente 15%
                                   height_shift_range=0.15,  # Mover imagen verticalmente 15%
                                   zoom_range=0.2)          # Acercar / Alejar aleatoriamente 20% => [80% - 120%]

```

Leer imagenes de carpeta conjunto train

```

training_set_imgs = datagen_train.flow_from_directory(project_folder + '/train',
                                                       target_size = (img_width, img_height),
                                                       class_mode = 'categorical',
                                                       batch_size = batch_size)

```

Fase de Modelado

MODELOS Y ALGORITMOS

```
for layer in incep_conv.layers[:]:  
    layer.trainable = False  
  
for layer in incep_conv.layers:  
    print(layer, layer.trainable)
```

```
# Model: "inception_resnet_v2"  
incep_conv = InceptionResNetV2(weights='imagenet', include_top=False, input_shape=(img_width, img_height, 3))  
incep_conv.summary();
```


```
model = Sequential()  
  
model.add(incep_conv)  
  
model.add(Flatten())  
  
model.add(Dense(4096, activation='relu'))  
model.add(Dropout(rate=0.4))  
model.add(Dense(4096, activation='relu'))  
model.add(Dropout(rate=0.4))  
model.add(Dense(6, activation='softmax'))
```

```
opt = Adam(lr=0.0001, beta_1=0.9, beta_2=0.999, amsgrad=False)  
#opt = SGD(lr=0.0001, momentum=0.9)  
model.compile(optimizer=opt, loss='categorical_crossentropy', metrics=['accuracy'])  
  
epochs=10  
history = model.fit_generator(training_set_imgs,  
                              epochs=epochs,  
                              steps_per_epoch=np.ceil(num_imgs_training/batch_size),  
                              validation_data=valid_set_imgs,  
                              validation_steps=np.ceil(num_imgs_valid/batch_size))
```

Fase de
Evaluación

MODELOS Y
ALGORITMOS

Validación en Test:
Loss: 0.3792
Accuracy: 88.08%




true label	cardboard	176	0	4	1	13	6
	glass	0	181	10	0	0	9
	metal	1	9	174	2	1	13
	organic	6	1	3	188	1	1
	paper	13	2	4	1	173	7
	plastic	2	14	5	2	3	174
predicted label		cardboard	glass	metal	organic	paper	plastic

Guardar
modelo y
predecir

MODELOS Y
ALGORITMOS

```
# Keras formato
carpeta_proyecto = "F:\Repositorios\DSRP_Semillero_ClasificacionResiduos"
model.save(carpeta_proyecto + "\Modelos\model_vgg16.h5", save_format='h5')
print("Modelo guardado en disco ...")
```

```
loaded_model = load_model(carpeta_proyecto + "\Modelos\model_vgg16.h5")
loaded_model.summary()
```



```
[0.01010183 0.00128938 0.0357519 0.00088975 0.7766795 0.17528763]
```

Index: 4

Pedición: paper

Prob: 0.7766795

```
folder_ejemplos = carpeta_proyecto+"/imgs"
img_ruta = folder_ejemplos + '/ejemplo_papel.jpg'
test_image = image.load_img(img_ruta)
plt.imshow(test_image, aspect="auto")
plt.show()

test_image = image.load_img(img_ruta, target_size = (img_width, img_height))
test_image = image.img_to_array(test_image)
test_image = np.expand_dims(test_image, axis = 0)
test_image = test_image.astype('float32')
test_image /= 255.0
```

```
predictions = loaded_model.predict(test_image)[0]
print(predictions)
index = np.argmax(predictions)
```

```
CLASSES = [ 'cardboard', 'glass', 'metal', 'organic', 'paper', 'plastic' ]
ClassPred = CLASSES[index]
ClassProb = predictions[index]
```

```
print("Index:", index)
print("Pedición:", ClassPred)
print("Prob:", ClassProb)
```

Comparación de modelos


MODELOS Y ALGORITMOS

VGG16


ResNet101V2

InceptionResNetV2


DenseNet201




Accuracy: 76.67%



Accuracy: 87.50%



Accuracy: 86.67%



Accuracy: 88.08%

¡Muchas gracias!



#yomequedoencasa